

IDEAL-RAG


用於檢索增強生成的
指令驅動雙觀點萃取與對齊連結方法

論文導讀

論文作者：王思正 國立成功大學資訊工程學系
碩士論文，2025 年

RAG 的基本流程

檢索外部文件，讓語言模型依據資料回答



文件品質
會影響答案品質

查到相關內容，
不代表查到正確內容。

研究問題：模型容易跟著錯誤文件回答

檢索端的問題

不相關段落、資訊不完整，或含有誤導性修改。

生成端的問題

模型可能優先採用外部內容，忽略自身已有的相關知識。

研究焦點：如何讓模型比較內外證據？

IDEAL-RAG 的三階段方法

先提出兩個來源的理由，再進行整合

01

萃取內部知識

只看問題，回想
相關背景知識。

02

生成雙方觀點

內部知識與外部文件
各自提出答案及理由。

03

連結推理與答案

比較支持與衝突之處，
形成最終回答。

雙觀點如何處理衝突

問題：誰贏得 2017 年 NCAA 女子籃球錦標賽？

模型回想的資訊

南卡羅來納大學奪冠

檢索文件中的衝突

正確片段：南卡羅來納大學

錯誤片段：聖母大學

整合結果

以內部知識與正確片段互相支持，回答南卡羅來納大學。

示例建構與測試作答

建構示例時

提供已知答案
生成雙觀點與整合說明
建立可供參考的示例

測試作答時

不提供該題答案
根據來源與示例立論
比較雙方後回答

使用方式：直接放入示例，或先進行輕量微調

實驗設定

基礎模型與比較方法

Llama-3-8B-Instruct，主要比較 InstructRAG。

四個問答資料集

PopQA、Natural Questions、TriviaQA、2WikiMultiHopQA。

後續圖表統一呈現「未額外訓練」設定

準確率依論文規則判定最終答案是否包含參考答案字串。

檢索污染測試

原始檢索

保留資料集的原始檢索內容，作為乾淨情境。

Counter-Mix：部分污染


將約半數含答案段落中的正確實體替換成錯誤實體。

Counter-All：全面替換答案

修改所有含答案段落中的答案片段。

全面污染下，NQ 與 TriviaQA 改善最明顯


未額外訓練，答案準確率（%），越高越好



NQ 提升約 26.9 個百分點，TriviaQA 提升約 25.0 個百分點

乾淨檢索下，準確率略低於 InstructRAG


未額外訓練，答案準確率（%），越高越好



主要收益來自抗污染能力，乾淨資料仍存在小幅落差

事先萃取知識是主要貢獻來源


Natural Questions，全面污染，答案準確率 (%)



保留知識萃取已能保住大部分表現，雙觀點再帶來改善

答案只在外部文件時，內部記憶可能拖累表現

Natural Questions，未額外訓練，答案準確率（%）



效果取決於內部知識能否提供正確且相關的資訊

研究限制與適用範圍

內部知識的品質是前提

記憶錯誤、過時或缺乏時，模型仍可能做出錯誤判斷。

部分任務與微調設定仍落後

PopQA 與多跳問答的已訓練版本，在全面污染下有反例。

部署成本與泛化仍待驗證

多次生成增加負擔，論文未完整報告延遲與 token 成本。

結論

先回想，再比較內外證據

強污染下可改善部分問答任務的準確率。

內部知識的品質，決定這個方法能幫上多少忙。

備用：可能的提問

需要兩個不同模型嗎？

不需要，可由同一模型以不同提示分工。

一定要微調嗎？

不一定，純提示版本也能執行。

是不是優先相信內部記憶？

目標是比較證據，但實驗顯示仍可能偏重內部。

適合直接取代一般 RAG 嗎？

需要依知識覆蓋率、資料風險與成本評估。